

Západočeská univerzita v Plzni
Fakulta aplikovaných věd
Katedra kybernetiky



PROJEKT 5
SEGMENTACE JATER PRASAT NA OBRÁZCÍCH CT

Yauheni Petrachenka
5. srpna 2024

1 Úvod

Hlavním cílem této práce je vycvičit neuronovou síť pro úlohu segmentace jater na obrázcích počítačové tomografie (CT). Pro tento účel bude použit model UNETR. Počáteční váhy sítě nebudou náhodně určeny — budeme replikovat experiment MONAI a získáme odpovídající model s váhami.

2 3D Multi-organ Segmentation with UNETR (BTCV Challenge)

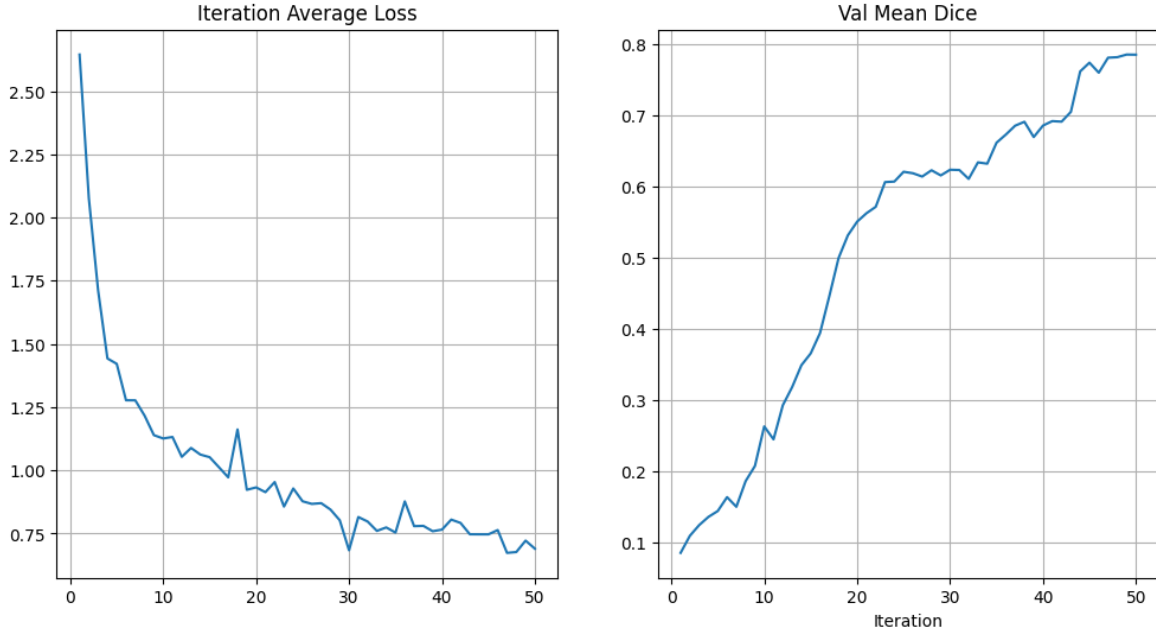
Byl replikován experiment uvedený v následujícím odkazu:

https://github.com/Project-MONAI/tutorials/blob/main/3d_segmentation/unetr_btcv_segmentation_3d.ipynb

Použitý dataset obsahuje následující třídy:

- Slezina
- Pravá ledvina
- Levá ledvina
- Žlučník
- Jícen
- Játra
- Žaludek
- Aorta
- Dolní dutá žíla (IVC)
- P&S žíla
- Slinivka břišní
- Nadledvinky

Model UNETR má následující parametry: požadovaný vstup obrázků: (96, 96, 96), pozicní vložení: 'perceptron', velikost funkce: 16, skrytá velikost: 768, počet hlav: 12, vstupní kanály: 1, výstupní kanály: 14. Jako ztrátová funkce byla použita DiceCELoss. Jako optimalizátor byl použit Adam a maximální počet iterací byl nastaven na 25000.



Obrázek 1: Výsledky učení


Obrázek 1 ukazuje výsledky učení. Výsledek byl podobný tomu získanému při prvním experimentu. Váhy této sítě byly zachovány a budou použity pro transfer learning.

3 UNETR Liver Segmentation for 3D CT Pigs Pictures


Poskytnutý dataset obsahuje 20 obrázků počítačové tomografie (CT). Ke každému obrázku byla poskytnuta anotace ve formátu COCO. Každý obrázek má rozlišení 512x512, přičemž ve směru osy Z se obrázky liší. Segmentace jater obsahují ne všechny obrázky, ale jsou důležité pro učení kvůli malému počtu dat. Všem pixelům, které obsahují pozadí, byla přidána hodnota 0, jinak byla hodnota pixelu vypočtena podle následujícího vztahu:

$$mask_value = \frac{category_id}{9} \cdot 255 \quad (1)$$


Po vytvoření masek byly obrázky načteny. Kvůli vysokým nárokům na paměť bylo nutné provést změnu velikosti obrázků s minimální ztrátou dat z rozlišení (900, 512, 512) na (272, 96, 96). Dataset byl rozdělen na trénovací množinu obsahující 17 obrázků a validační množinu obsahující 3 obrázky. Před učením byly zkopírovány váhy z předchozího experimentu do našeho modelu. Pro trénování byl použit UNETR model s následujícími parametry: požadovaný vstup obrázků: (272, 96, 96), pozicní vložení: 'perceptron', velikost funkce: 16, skrytá velikost: 768, počet hlav: 12, vstupní kanály: 1, výstupní kanály: 1. Jako ztrátová funkce byla použita DiceCELoss. Jako optimalizátor byl použit Adam a maximální počet iterací byl nastaven na 25000.



Obrázek 2: Ztrátová funkce



Obrázek 3: přesnost modelu při trénování



Obrázek 4: přesnost modelu při validaci

Obrázky 2, 3 a 4 znázorňují průběh ztrátové funkce a přesnost modelu během trénování a validace. Model dosáhl relativně dobré přesnosti přibližně 0.85. Grafy ukazují, že na začátku učení dochází k výraznému skoku, což může být způsobeno použitím metody transfer learning.

4 Závěr

Požadované cíle byly dosaženy. Byly získány váhy trénovaných modelů a záznamy o přesnosti modelů v průběhu trénování a validace. Učení proběhlo na platformě Meta-Centrum.